

SESIÓN 02

Abrir la caja

Tokenización · Self-attention · Posición

La sesión de hoy.



Revisemos la Plantilla de cada grupo



Tokenización + Lab



Self-attention + Lab



La posición + Lab

BLOQUE 01

Equipos oficiales

10 minutos · Revisión del proyecto

Cerremos la definicion de grupos y dominios y demos un vistazo a la plantilla con los apartados 1 y 2.

Equipos y dominios

SI4006 · Tópicos Especiales y Aplicaciones en IA · Sesión 1 — primer acercamiento

24

estudiantes · 6 equipos

GRUPO 1

4 integrantes

Educación

- Camilo Arbeláez
- Felipe Castro
- Emanuel Castañeda
- Miguel Mercado

GRUPO 2

4 integrantes

E-commerce

- Sebastián Castaño
- Valeria Honnung
- Maximiliano Bustamante
- Alejandro Sepúlveda

GRUPO 3

4 integrantes

Salud pública

- María Alejandra Ocampo
- Isabella Idárraga
- Camilo Salazar
- Juan Esteban Alzate

GRUPO 4

3 integrantes

Agro y clima

- Luciana Hoyos
- Juan Carlos Citelly
- Santiago Manco

GRUPO 5

5 integrantes

Legal

- Santiago Gómez
- Nicolás Saldarriaga
- Martín Vanegas
- Lucas Higueta
- Tomás Posada

GRUPO 6

4 integrantes

Vet · Salud pública · Turismo

- Luis Ángel Nerio
- Paula Llanos
- Isabella Camacho
- Agustín Figueroa

Borrador de la Sesión 1. Se confirma en S02 con la plantilla de definición del proyecto (campos 1 y 2: dominio · usuario y decisión).

Esto queda oficial

Cambiar de equipo o de dominio después no es imposible. Es caro.

S04

Modelo base fine-tuneado sobre su dominio

S06

Harness de evaluación construido para su dominio

S10

RAG con corpus de su dominio, encima de todo lo anterior

S13

Componente visual integrado al sistema

Cada capa se apila sobre la anterior. En la semana 10, cambiar de dominio cuesta seis semanas.

BLOQUE 02

Tokenización

Un modelo no lee texto.

Lee números.

El tokenizador es el traductor entre los dos mundos.
Y como todo traductor, tiene opiniones.

¿Cuál es la unidad?

Antes de traducir hay que decidir qué es una pieza. Tres respuestas posibles, tres formas de perder.

Carácter

h · o · l · a

✓ Vocabulario diminuto.
Nunca hay palabras desconocidas.

✗ Secuencias larguísimas.
El modelo gasta capas aprendiendo a deletrear.

Palabra

hola

✓ Cada pieza significa algo.
Secuencias cortas.

✗ Vocabulario infinito.
¿Y "antidisestablishmentarianism"?
¿Y los errores de tipeo?

Subpalabra

ho · la

✓ Lo frecuente, una pieza.
Lo raro, en pedazos.
Nunca falla.

✗ Nada es gratis:
lo "raro" lo define el corpus
de entrenamiento.

Todos los modelos modernos usan subpalabra. La pregunta ya no es cuál — es cómo se decide dónde cortar.

BPE — Byte Pair Encoding

Un algoritmo de compresión de 1994, reciclado para la IA en 2015.

1

Empieza por caracteres

Cada letra es una pieza. Vocabulario mínimo.

2

Cuenta los pares

¿Qué dos piezas aparecen juntas más veces en el corpus?

3

Fusiona el par más frecuente

Ese par se vuelve una pieza nueva del vocabulario.

4

Repite

Hasta llegar al tamaño de vocabulario que se fijó.

El algoritmo nunca vio un diccionario

No sabe qué es una palabra, ni una raíz, ni un sufijo.

Solo cuenta frecuencias.

Que "ción" termine siendo una pieza no es lingüística: es estadística. Y por eso el resultado depende por completo de qué había en el corpus.

Consecuencia directa: lo que su corpus no tenía, su tokenizador lo va a despedazar. Guárdenlo para el Lab A.

Tres familias, un mismo problema

¿Cómo represento el espacio en blanco? Las tres lo resolvieron distinto — y por eso se distinguen a simple vista.

FAMILIA	FIRMA	CRITERIO DE FUSIÓN	MODELOS
BPE	Ġ	El par más frecuente	GPT, LLaMA, Qwen
WordPiece	##	El par que más sube la verosimilitud	BERT, DistilBERT
SentencePiece	—	Trata el espacio como un carácter más	T5, XLM-R, Gemma

Con esto pueden identificar de qué familia es un tokenizador con solo mirar su salida. Lo van a hacer en cinco minutos.

LABORATORIO A

Forense de tokenizadores

25 minutos · abran el notebook

- ¿Cuánto cuesta su apellido, comparado con "Smith"?
- ¿Cuánto más caro es operar un chatbot en español?
- ¿Por qué estos modelos son malos para la aritmética?
- ¿Qué le hace el tokenizador a la jerga de SU dominio?

BLOQUE 03

Self-attention

Ya tenemos vectores. ¿Y ahora?

Del Lab A salieron tokens. Cada token es un vector. El problema es que ese vector no sabe dónde está parado.

Embedding estático

word2vec, GloVe

banco

→ un solo vector, siempre

El banco del parque, el banco que presta plata y el banco de peces comparten exactamente el mismo punto del espacio.

El vector se calculó antes de ver la frase.

Embedding contextual

cualquier transformer

me senté en el banco

→ cerca de "silla"

el banco me negó el crédito

→ cerca de "entidad financiera"

Misma palabra. Vectores distintos.

El contexto los movió.

Q, K, V

Los tres papeles que juega cada token. La metáfora es una búsqueda — porque literalmente es una búsqueda.



Query

Lo que este token está buscando
"soy un verbo, ¿dónde está mi sujeto?"



Key

Lo que este token ofrece a los demás
"soy un sustantivo, puedo ser sujeto"



Value

Lo que este token entrega si lo eligen
el contenido que se va a promediar

Salen del mismo vector

$$Q = X \cdot W^Q$$

$$K = X \cdot W^K$$

$$V = X \cdot W^V$$

Tres matrices aprendidas. El mismo token se presenta distinto según sea el que pregunta, el que se ofrece o el que entrega.

Eso es todo lo que se entrena aquí.

En el Lab B van a usar $Q = K = V = X$, sin matrices. Self-attention en su forma más desnuda.

Toda la arquitectura, en una línea

$$\text{Attention}(Q, K, V) = \text{softmax}(Q \cdot K^T / \sqrt{d}) \cdot V$$

$Q \cdot K^T$

¿Qué tan relevante eres para mí?

Un producto punto es una similitud. Cada token le pregunta a cada token.

Es la MISMA operación de `doc_emb @ q.T` de la Sesión 1.

$\div \sqrt{d}$

Plomería que decide todo

Sin esto, los puntajes crecen con la dimensión, el softmax se satura y el gradiente muere.

Un sqrt separa una arquitectura que entrena de una que no.

$\text{softmax} \cdot V$

Promedio ponderado

Los puntajes se vuelven pesos que suman 1, y con ellos se promedian los valores.

Y ya. Eso es la atención.

La atención es un promedio ponderado donde los pesos los decide una similitud. Nada más.

LABORATORIO B

Attention a mano

35 minutos · tres TODO, tres líneas

```
def atencion(Q, K, V):  
    d_k = Q.size(-1)  
    scores = ____  
    pesos = ____  
    salida = ____  
    return salida, pesos
```

La meta

¿Coincide con PyTorch? True

Si les da True, escribieron el motor de todos los modelos que vamos a usar el resto del semestre.

La solución está plegada. Ábranla solo después de diez minutos peleando.

Pausa

15 minutos

Volvemos directo al notebook. No cierren Colab.

La atención no sabe de orden

El perro mordió al hombre.

El hombre mordió al perro.

Mismas palabras. Significados opuestos. Una es un martes cualquiera; la otra es noticia.

La atención que ustedes acaban de escribir, ¿las distingue?

Voten antes de correr la celda. · 20 minutos

BLOQUE 04

La posición

Lo que acaban de encontrar

$$\text{softmax}(Q \cdot K^T / \sqrt{d}) \cdot V$$

Busquen la posición en esa fórmula.
No está. Nunca estuvo.

La self-attention pura es una bolsa de palabras.

Una bolsa muy sofisticada — pesa cada palabra según su relación con las demás — pero una bolsa. El orden se le escurre.

Equivariante, no invariante

$$\text{atención}(\text{permutar}(X)) = \text{permutar}(\text{atención}(X))$$

Permutó la entrada y la salida se permuta igual. El vector de cada token no cambia.

Por qué importa la precisión

Sí conserva QUÉ tokens hay y CON QUIÉN se relaciona cada uno.

Lo único que perdió es DÓNDE estaban. Por eso el arreglo puede ser barato.

¿Y si le sumamos 1, 2, 3, 4?

Es la primera idea de todo el mundo. Falla por dos razones distintas.

Entero

`pos = 1, 2, 3 ... 2000`

La señal aplasta el significado

Con 2000 tokens, la posición vale 1999 y el embedding vale ~4.

Al sumarlos, el modelo deja de ver qué palabra es. Solo ve dónde está.

Normalizado

`pos / longitud → [0, 1]`

Depende de la longitud total

Arregla la magnitud, pero ahora la posición 3 de una frase de 5 vale lo mismo que la 1200 de una de 2000.

El modelo nunca aprende qué es "la tercera palabra".

Sinusoidal

`sin/cos de varias frecuencias`

Acotada y absoluta

Siempre entre -1 y 1, sin importar la longitud.

Cada posición tiene un valor propio que no depende del tamaño de la frase.

Esta tabla está en la versión resuelta del notebook. Córranla: la columna del entero da 1999 y se ve el problema de una.

Senos y cosenos

La respuesta de 2017. Cada posición recibe una huella digital hecha de ondas de distintas frecuencias.

```
PE(pos, 2i)    = sin(pos / 10000^(2i/d))  
PE(pos, 2i+1) = cos(pos / 10000^(2i/d))
```

La cuarta propiedad es la importante

Le da al modelo una forma de razonar sobre distancias RELATIVAS, no solo absolutas. Guárdenla: es el hilo hacia RoPE.

- **Acotada**
Siempre entre -1 y 1. Nunca aplasta al embedding, sea la frase de 5 o de 5000 tokens.
- **Única por posición**
Cada posición recibe un patrón distinto: la combinación de frecuencias no se repite.
- **Suave**
Posiciones cercanas reciben patrones parecidos. "Cerca" significa algo en el espacio.
- **Lineal en el desplazamiento**
Por identidades trigonométricas, $PE(pos+k)$ es una transformación lineal de $PE(pos)$.

¿Y por qué no dejar que la aprenda?

Es lo que hizo BERT. Una tabla de embeddings, una fila por posición, entrenada como cualquier otro parámetro.

	SINUSOIDAL	APRENDIDA
Origen	Fórmula fija, cero parámetros	Tabla entrenada, un vector por posición
Modelos	Transformer original, T5	BERT, GPT-2
Longitudes nuevas	Extrapolación: la fórmula existe para cualquier posición	Se rompe: la posición 513 nunca se entrenó
Calidad	Prácticamente igual dentro del rango entrenado	Prácticamente igual dentro del rango entrenado

Fila 3 · Ese es el problema que ninguna de las dos resuelve bien — y la razón de que apareciera RoPE.

RoPE

Rotary Position Embedding · lo que usan LLaMA, Qwen, Mistral — y el modelo que corrieron la semana pasada

La pregunta que se hicieron: si lo que importa son las distancias relativas, ¿por qué codificamos la posición absoluta?

Que "no" esté justo antes de "vigente" importa muchísimo.

Que sea la palabra 340 o la 890 no le importa a nadie.

● No suma. Rota.

En vez de sumarle una señal al embedding, rota los vectores Q y K en un ángulo proporcional a su posición.

● Los ángulos se restan

Al calcular $Q \cdot K^T$, las rotaciones se cancelan y queda solo la DIFERENCIA de posiciones. Lo relativo sale gratis, sin aprenderlo.

● Extrapola

Como la rotación es una función continua de la posición, no hay una "fila 513" que nunca se entrenó.

Está en la versión resuelta del notebook, con el detalle. Y en la profundización de la unidad.

Multi-head

Una sola atención tiene que decidir a qué prestarle atención. ¿Y si hay varias cosas que importan a la vez?

Una cabeza de 512

Un solo promedio ponderado. Un solo criterio de relevancia para toda la frase.

Ocho cabezas de 64

Ocho atenciones en paralelo, cada una con sus propias W_q , W_k , W_v . Se concatenan al final.

Mismo costo. Ocho preguntas distintas al mismo tiempo.

Las cabezas no se coordinan ni se reparten el trabajo por diseño. Nadie les asignó un papel: se especializan solas durante el entrenamiento, y en modelos entrenados se han encontrado cabezas que siguen sintaxis, otras que rastrean correferencia, otras que simplemente miran al token anterior. Emergió, no se programó.

Y una advertencia honesta: es tentador abrir un modelo, encontrar una cabeza que "hace sintaxis" y contar esa historia. La literatura de interpretabilidad está llena de patrones que resultaron ser menos limpios de lo que parecían. Miren, disfruten, y desconfíen.

El banco

me senté en el banco

el banco me negó el crédito

Lo que todavía le falta

Lo que escribieron hoy es el corazón. Un bloque transformer completo le agrega cuatro cosas — y esa es la Sesión 3.

- **Proyecciones aprendidas**

$Q = X \cdot W_q$, $K = X \cdot W_k$, $V = X \cdot W_v$ en vez de $Q = K = V = X$

- **Multi-head**

Varias atenciones en paralelo, concatenadas

- **Residuales + LayerNorm**

$x + \text{atención}(x)$. Es lo que permite apilar 96 capas sin perder la señal

- **Red feed-forward**

Un MLP por posición. Ahí vive la MAYORÍA de los parámetros — no en la atención

El punto 4 es el que sorprende a todo el mundo: la atención es el mecanismo famoso, pero no es donde está la mayoría del modelo.

Tarea para S03

1

**Leer la sección 3 de
Attention Is All You Need**

arxiv.org/abs/1706.03762

Ya escribieron la ecuación 1. Ahora la van a reconocer en el paper — y la van a leer distinto de como la habrían leído ayer.

2

**Candidato a modelo base
para M1, por equipo**

Criterio nuevo, cortesía del Lab A: miren cómo tokeniza su dominio antes de enamorarse de un modelo. Nadie más va a llegar con ese argumento.

Lo que se llevan

1

El tokenizador tiene opiniones

Y algunas cuestan plata. Su proyecto es en español: ya saben lo que significa.

2

La atención es un promedio ponderado

Los pesos salen de una similitud. Nada más. Lo demás es escala y plomería.

3

La atención no sabe de orden

Alguien tuvo que sumársela a mano, y esa decisión sigue evolucionando hasta hoy.

Y una cuarta, que no está en el temario: hoy construyeron algo, descubrieron que estaba roto, y lo arreglaron. Ese ciclo es el trabajo — no el camino hacia el trabajo.

Tres líneas.

Eso es todo lo que sostiene a todos los modelos que vamos a usar este semestre. Y ya las escribieron.

```
softmax( Q · KT / √d ) · V
```

Nos vemos en S03.