

¿Es bueno de verdad?

El modelo ya aprende del dominio y la pérdida (training loss) baja, pero no es segura que sirva. Empezamos el Módulo 2: cómo medir si un sistema generativo es bueno, y por qué evaluarlo es más difícil que evaluar un clasificador.

[EVALUAR GENERATIVOS](#)[MÉTRICAS Y SUS LÍMITES](#)[SU PROPIO EVAL SET](#)

La sesión de hoy.



Recap y pregunta “trampa”



Métricas clásicas de generación  Lab A



Perplexity y cross-entropy



Benchmarks modernos y su letra pequeña  Lab B



Contaminación → eval set específico




Hacia su harness (S06) y tarea

Entrena y, ¿sirve?

Las métricas numéricas, como accuracy, solas no dicen mucho y no aseguran si un modelo es bueno.

Lo que midieron en M1.



En M1 lo normal sería reportar algo como **“la métrica subió de X a Y”** o **“el resultado se ve ‘mejor’”**.

Vamos a convertir ese “se ve mejor” en algo que se pueda **medir, defender y reproducir**.

“Mi modelo tiene **78% de accuracy.**”

¿Bueno?, ¿suficiente? ¿es bueno **comparado con qué?** ¿Y si la clase mayoritaria ya acierta el **75%**?
(¿sesgos?)

Si el modelo **genera texto** en vez de clasificar, “**accuracy**” no sirve para medir. No hay una única respuesta correcta con la cual comparar carácter por carácter.

Un clasificador se corrige solo. Un generador, no.

CLASIFICAR



Hay UNA respuesta

Si existe etiqueta correcta, y solo si existe, Accuracy y recall, precisión y todas las combinaciones pueden servir.

GENERAR



Hay MUCHAS respuestas

Dos textos con palabras totalmente distintas pueden ser “igual” de buenos. ¿Cómo los comparo?

EL RIESGO



Medir lo fácil

Es tentador medir lo que sí se puede contar (palabras) y llamarlo calidad, pero... ¿lo es?

Contar palabras en común.

BLEU, ROUGE, METEOR y BERTScore
¿Cuándo sí y cuándo no?

BLEU y ROUGE: cuántas palabras coinciden.

BLEU

Precisión de n-gramas

De lo que el modelo dijo, ¿cuánto aparece en la referencia? Nació para traducción.

ROUGE

Recall de n-gramas

De la referencia, ¿cuánto recuperó el modelo? El estándar de resumen.

METEOR

+ sinónimos y raíces

Como BLEU, pero acepta sinónimos y palabras con la misma raíz. Un poco más justa.

Se diseñaron cuando los modelos eran **malos**. Miden **solapamiento de palabras, no significado**; con modelos modernos capturan poco.

La métrica depende de qué hace su modelo.

FAMILIA (S03)	CÓMO SE MIDE	OJO CON
 Encoder Clasificar / extraer	accuracy • F1 • matriz de confusión	el baseline / ground truth
 Decoder Generar / conversar	perplexity • LLM-as-a-judge • humano	creer que hay una única respuesta y con cómo se determina
 Enc-dec Transformar texto→texto	BLEU • ROUGE • METEOR • BERTScore	paráfrasis válidas

Conformarse con una sola métrica no es lo recomendable

BERTScore: comparar por significado.

En vez de contar palabras exactas, convierte cada texto en embeddings y compara qué tan cerca están en significado. Una paráfrasis con otras palabras, pero el mismo sentido, puntúa alto donde BLEU se hundiría.

Es la misma idea del **coseno entre embeddings**, vamos a ver que tal les va a BLEU y ROUGE

Al notebook — Lab A

Las métricas, y dónde se rompen

Tomen una frase de referencia y tres candidatos: una copia casi exacta, una paráfrasis perfecta con otras palabras, y un texto fluido pero incorrecto. Calculan BLEU y ROUGE, y una similitud por embeddings.

```
bleu • rouge   vs   similitud por embeddings   →   S05_Lab_Metricas_de_evaluacion.ipynb
```

Qué acaban de medir.

- **Copia casi exacta** todo alto — el caso fácil, donde cualquier métrica funciona.
- **Paráfrasis perfecta** BLEU y ROUGE se hunden aunque el significado es idéntico. El fallo clásico.
- **Embeddings** rescatan la paráfrasis: miden sentido, no palabras exactas.
- **Fluido pero falso** suena bien y ninguna métrica sola lo caza → hace falta más de una dimensión.

¿Qué tan sorprendido?

Una métrica intrínseca conectada a cross-entropy.

Perplexity: la sorpresa del modelo.

Mide qué tan probable le resulta al modelo el texto que ve. Perplexity baja = el modelo “no se sorprende”, predice bien las palabras que vienen. Es la exponencial de cross-entropy.

La definición, en una línea:

$$\text{perplexity} = \exp(\text{cross-entropy})$$

Es la métrica “intrínseca”: no necesita respuestas de referencia, solo el texto y el modelo.

<https://huggingface.co/docs/transformers/perplexity>

Cuándo perplexity engaña.

- **Mismo texto, mismo tokenizer.** solo es comparable entre modelos evaluados sobre EL MISMO texto y con el MISMO tokenizer.
- **No entre datasets.** una perplexity de 12 en un corpus y 30 en otro no se pueden comparar: son escalas distintas.
- **Fluidez $\neq$ utilidad.** mide qué tan probable es el texto, no si la respuesta es correcta, veraz o útil para su usuario.

Los benchmarks.

MMLU, GSM8K, MT-Bench, HELM: qué mide cada uno, qué no, y cómo leerlos con ojo crítico.

Cada benchmark mide una cosa.

BENCHMARK	QUÉ MIDE	QUÉ NO MIDE
 MMLU	Conocimiento en 57 temas (opción múltiple)	razonamiento real; se contamina fácil
 GSM8K	Razonamiento matemático paso a paso	dominios fuera de matemáticas
 MT-Bench	Calidad conversacional (juzgada por un LLM)	tareas cerradas o factuales
 HELM	Multidimensional: exactitud, sesgo, costo	no da un solo número mágico
 BIG-bench	Tareas raras y difíciles a propósito	tareas cotidianas de su dominio

Ninguno mide SU dominio. Un buen puntaje aquí no garantiza un buen sistema para su usuario.

Debajo de todo hay una regla simple.

EXACT-MATCH

¿Coincide exacto?

La respuesta del modelo debe igualar la esperada, carácter por carácter.
Simple y estricta.

OPCIÓN MÚLTIPLE

Accuracy

El modelo elige A/B/C/D; se cuenta cuántas acertó. Así funciona MMLU.

PASS@K

¿Alguna de k sirve?

En código: se generan k intentos y basta con que uno pase los tests.
Métrica de HumanEval.

Un “85%” es siempre 85% según ALGUNA regla. Entender la regla es entender qué está midiendo.

Un leaderboard **no** es la verdad.

- Un número alto puede venir de **contaminación** (el test se filtró al entrenamiento).
- O de **prompt-tuning** para ese benchmark, que no se traslada a su tarea.
- O de un test que **no se parece** en nada a lo que su usuario necesita.

Al notebook — Lab B

Un benchmark por dentro

Cargan unas cuantas preguntas de un benchmark real (MMLU) y las inspeccionan: el formato de opción múltiple, la respuesta esperada y la regla de puntuación. Discuten por qué un modelo podría “acertarlas” sin razonar de verdad.

```
load_dataset('cais/mmlu', ...) • ver formato + exact-match → Lab B
```

Qué vieron por dentro.

- **Un benchmark** es un dataset con respuestas fijas + una regla de puntuación (aquí, exact-match).
- **Es cómodo y comparable** pero mide UNA cosa y es fácil de contaminar o de sobre-ajustar.
- **Ninguno mide su dominio** por eso el paso siguiente es construir el suyo — su propio eval set.

Por qué “mejoran” solos.

El sesgo silencioso que infla los leaderboards — y por qué obliga a tener eval propio.

Memorizar no es razonar.

Si las preguntas del test se colaron en los datos de entrenamiento, el modelo las “sabe” porque las vio, no porque razone. El puntaje sube sin que el modelo sea mejor. Como los modelos se entrenan con casi todo internet, pasa más de lo que parece.

Cómo se detecta: solapamiento de n-gramas entre test y train, “canary strings” escondidas, o una caída fuerte del puntaje al reformular la misma pregunta.

La consecuencia práctica: lean todo leaderboard con esta duda encima.

Construyan su **propio eval set**.

Un conjunto de ejemplos de SU dominio (**input + salida esperada**) es la única medida que:

- no está contaminada — la hicieron ustedes,
- mide lo que a SU usuario le importa,
- y sirve de vara fija el resto del semestre (RAG en M3, visión en M4, producción en M5).

Es la base de M2. Hoy traen la semilla; en S06 lo vuelven un harness ejecutable.

Hacia su harness.

Las tres dimensiones de una buena evaluación, y lo que traen para S06.

Tres dimensiones, no una.

1 • MÉTRICA CLÁSICA



Automática y barata

BLEU/ROUGE/embeddings o accuracy.
Rápida y reproducible, pero con sesgos conocidos.

2 • LLM-AS-A-JUDGE



Un LLM califica

Con una rúbrica, un modelo juzga la respuesta. Potente y peligroso, lo vemos la siguiente semana bien.

3 • DE DOMINIO



Su eval set

Sus ejemplos, su criterio de “buena respuesta”. La única que mide lo que de verdad importa.

El RAS de M2: un marco con al menos estas tres dimensiones, produciendo un scorecard del baseline.

Qué hace bueno a un eval set.

REPRESENTATIVO

Los ejemplos se parecen a lo que su usuario real preguntará, no a los casos más fáciles.

CON SALIDA ESPERADA

Cada input trae la respuesta correcta (o una rúbrica de qué la haría correcta).

CUBRE CASOS DIFÍCILES

Incluye los bordes: ambigüedad, casos raros, cosas donde el modelo se suele equivocar.

NO CONTAMINADO

Lo escriben ustedes o lo curan a mano; no sale tal cual de un benchmark público.

Cuando la métrica son las personas.

Chatbot Arena enfrenta dos respuestas anónimas a la misma pregunta y deja que miles de personas voten cuál prefieren. Con esos votos arma un ranking Elo, como en ajedrez. Preferencia relativa entre modelos, a gran escala.

Por qué es buena idea: captura preferencia humana real, difícil de falsear.

Sus límites: sesga hacia respuestas largas y seguras, y no controla el dominio — un modelo bueno “en general” puede ser malo para su caso.

Lo que traen la próxima semana.

1

Diez ejemplos gold de su dominio: input + salida esperada

2

Respuesta a: ¿qué hace “buena” una respuesta en su dominio? Ese es su criterio.

3

Con eso lo volvemos ejecutable: harness + scorecard del baseline = entrega M2

Ya no preguntan “¿entrenas?”.
Preguntan “¿es bueno?”.

La próxima semana lo vuelven ejecutable: LLM-as-a-judge, evaluación humana y su harness — la entrega M2.